

预测 Hyperliquid 比特币波动率代理值的次日更新时，随机森林和 LSTM 增加的复杂度是否值得？

摘要

本项目比较滚动历史波动率、GARCH(1,1)、滞后线性回归、随机森林和长短期记忆网络 (LSTM)，目标是预测日度比特币波动率代理值的次日更新。数据来自 Hyperliquid 比特币永续期货的完整日线。主要目标是次日更新后的 30 日对数收益率标准差。相邻目标共享 29 个收益率，所以这里预测的是一次更新，不是完整的未来 30 日波动率。主要测试采用固定的时间顺序划分，并用 14 日目标、不同时段、不同波动率区间、扩展窗口、区块自助法和七日数据刷新检查结果是否稳定。评价指标包括 RMSE、MAE 和 QLIKE，同时比较解释难度和实际成本。

GARCH(1,1) 的 RMSE (0.00098502) 和 QLIKE (0.00370047) 都最低，RMSE 比滚动基准低 30.994%，并且在所有补充检查中排名第一。随机森林和 LSTM 整体上都没有超过滚动基准。因此，在本次实验中，两种机器学习模型增加的复杂度没有带来足够的预测改进。这个结论只适用于本文的数据、目标、输入和模型设置。

1. 引言

波动率描述的是收益率变化的幅度，而不是价格变动的方向。价格方向预测询问比特币将上涨还是下跌；波动率预测则询问下一时期可能有多大的不确定性或变动性。即使交易者和风险管理者不知道下一期收益率的正负号，也可以在设定头寸规模、风险限额或抵押品缓冲时使用这样的估计。加密货币适合于这项研究，因为剧烈波动和持续的市场压力使不断变化的不确定性清晰可见，而公开的交易所数据使独立复现这一比较成为可能。

研究问题是：

在预测由 Hyperliquid 比特币永续期货收益率构建的波动率代理值的次日更新时，与滚动历史波动率和 GARCH(1,1) 相比，随机森林和 LSTM 增加的复杂度在多大程度上值得？

研究目的 (Aim) 是判断：在预测这一滚动值的次日更新时，与滚动历史波动率和 GARCH(1,1) 相比，随机森林和 LSTM 增加的复杂度是否值得。具体目标 (Objectives) 是：

1. 使用完整的 Hyperliquid 比特币永续期货蜡烛图，可复现地构建 14 日和 30 日滚动标准差代理值；
2. 在无测试集泄漏的条件下，实现滚动历史波动率、GARCH(1,1)、滞后线性回归、scikit-learn 随机森林和 LSTM；
3. 使用 RMSE、MAE 和 QLIKE 比较预测准确性；
4. 在目标窗口、时间区段、波动率状态、重采样、滚动起点重新拟合和固定截点刷新中检验稳健性；
5. 使用实际产生的解释、依赖与调参负担、结构规模及本地运行时间比较可解释性和实用性；
6. 判断任何机器学习增益是否足够大且稳定，能够证明额外复杂性的合理性。

本文从准确性、稳健性、可解释性和实用性四方面比较模型，并在所有实验中保持相同的复现要求。复杂模型不能只因为一次排名略高就被选中；它需要带来明显而且稳定的改进。

滞后线性回归是辅助模型，用来检验工程化特征是否无须非线性学习器也能发挥作用。滚动模型是持续性基准，GARCH 是条件方差基准，随机森林是非线性表格学习器，LSTM 是非线性序列学习器。结果比较的是完整预测流程，而不是孤立的架构。资产特指 Hyperliquid 比特币永续期货，因此结论不能直接推广到其他交易所或现货市场。

评估日期固定为 2025 年十一月 16 日，而不是每次下载后重新计算移动的 80/20 边界。最终代码分别在截至 2026 年七月 12 日的数据切片和截至七月 19 日的当前输入上运行，从而在不把旧测试行移入训练集的条件下检验七个新增完整交易日。

2. 文献综述

2.1 为什么 GARCH 仍是不可轻视的基准模型

金融收益率方差通常不会随时间保持恒定。大幅波动往往聚集出现，平静时期亦然。Bollerslev (1986) 提出了广义自回归条件异方差模型，使条件方差可以取决于近期冲击的平方和先前的条件方差。因此，GARCH(1,1) 是围绕持续性设计的，而不是套用于时间序列的一般回归。

Hansen 和 Lunde (2005) 的研究说明了为什么不应将 GARCH(1,1) 视为一个弱基准。他们对 330 种 ARCH 类模型进行了样本外比较。对于汇率数据，他们没有发现更复杂模型优于 GARCH(1,1) 的证据，尽管非对称模型在 IBM 收益率上表现更好。其启示是有条件的：GARCH 在一种情境中可能很难被超越，而在另一种情境中却可能不够充分。Katsiampa (2017) 也支持对比特币采用条件方差建模；在其样本内测试的若干 GARCH 族设定中，带自回归成分的 GARCH 模型表现最强。两项研究都没有证明简单 GARCH 必然会赢得本次实验；二者共同说明，将其视为有力竞争者是合理的。

2.2 关于机器学习的混合证据

机器学习文献并未给出一种稳定的排名。Dudek 等人 (2024) 在四种加密货币上比较了 12 种统计和机器学习方法，包括 GARCH、随机森林和 LSTM。模型表现因资产、损失函数和预测期限而异，简单的线性方法也可能与更复杂的学习器相当。然而，他们的已实现方差由日内收益率构建，信息比本研究使用的日度滚动代理指标更丰富。

Huang、Sangiorgi 和 Urquhart (2024) 给出了相反的结果。他们使用 2014 至 2021 年的高频比特币数据，报告神经网络在所测试的各个期限上均优于 GARCH。他们的 LSTM 和 CNN-LSTM 模型获得了更丰富的数据变换和更多日内观测值，因此小型日度数据 LSTM 并不是等价的复现实验。Shen、Wan 和 Leatham (2021) 也发现循环网络按平均预测评价指标衡量时表现更好，但对极端事件和风险价值的效果较弱。这一区别支持评估高波动率时期的表现，而不是只依赖总体 RMSE。

混合模型研究削弱了统计方法与机器学习方法彼此对立的观点。Zahid、Iqbal 和 Koutmos (2022) 将 GARCH 结构与机器学习相结合，用于预测比特币已实现波动率。混合模型是合理的扩展方向，但如果在确立各自独立基准之前就实施混合模型，将更难识别改进的来源。Catania、Grassi 和 Ravazzolo (2019) 进一步表明，加密货币的可预测性会受到模型和参数不稳定性的影响。本项目采用固定的时间顺序留出集、两个时间分段和四个扩展窗口区块来应对这一问题。这些检验比单次划分更有力，但它们仍来自同一段市场历史，而不是相互独立的外部样本。

2.3 特征、序列与可解释性

Breiman (2001) 将随机森林描述为随机化决策树的集成。自助抽样和随机特征选择降低树与树之间的依赖，而平均则降低方差。该方法能够捕捉阈值和交互作用，无须假设线性方程。然而，在时间序列研究中，它不会自动知晓时间顺序；过去的信息必须通过滞后项和滚动特征来表示。因此，特征设计是模型的一部分，而不是中性的预处理。

Hochreiter 和 Schmidhuber (1997) 提出 LSTM，以解决循环神经网络在学习较长依赖关系时面临的困难。其门控机制控制哪些信息被保留、更新和输出。这种架构看似适合具有持续性的波动率，但适用性并不等于准确性的证明。序列长度、隐藏层大小、缩放、学习率、正则化和停止条件都很重要，特别是在只有约一千个训练观测值的情况下。

可解释性也必须谨慎定义。Lundberg 和 Lee (2017) 与 Molnar (2025) 说明，不同解释工具回答不同问题。本项目只认可实际产生的证据：GARCH 的方程和参数；线性回归带符号的标准化系数；随机森林的不纯度、置换重要性和袋外诊断；以及 LSTM 的架构、损失、种子稳定性和事后输入消融敏感性。重要性 with 消融只反映关联，可能受相关输入影响，也不能对单次预测作因果解释。

2.4 波动率的代理指标

真实条件波动率是潜在变量。Patton (2011) 表明，模型排名可能取决于不完美代理指标和损失函数，因此本研究把平方后的代理值与预测值放到方差尺度上，补充报告 QLIKE。高频已实现方差通常比基于单个日收盘价的滚动标准差包含更多信息；加入 QLIKE 能改进评价，但不能消除代理指标本身的局限。因此，本研究称其为 *日度波动率代理指标*，而不是比特币的潜在真实波动率。

该代理指标具有一项重要的结构特征：明日主要窗口中的 30 个收益率，有 29 个在今日已经知晓。因此，持续性既有数学成因，也有实证成因。滚动波动率是一个要求很高的操作性基准，模型要超越它，就必须更准确地估计进入窗口的收益率和离开窗口的收益率所产生的影响。这一设计适合预测更新后的单日提前风险指标，但不同于预测一个完全位于未来且不与当前窗口重叠的 30 日窗口。

总的来说，文献支持开展这一比较，但没有预先决定答案。GARCH 具有扎实的理论和实证基础；机器学习在更丰富的数据和设计下可能超过它；简单方法也可能保持竞争力。因此，本研究只回答这套日度数据和实验设置下的问题。

由此可以提出三项预期。由于目标重叠，滚动波动率应该很难被超过。如果近期冲击有助于估计新进入窗口的收益率，GARCH 可能受益。随机森林和 LSTM 只有在非线性关系或序列模式提供额外信息时才会受益。这些是需要检验的预期，不是对结果的预设。

3. 数学表述

设 P_t 为第 t 日的每日收盘价。对数收益率为

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right).$$

对于 n 日窗口，日度已实现波动率代理指标是样本标准差

$$RV_t^{(n)} = \sqrt{\frac{1}{n-1} \sum_{i=t-n+1}^t (r_i - \bar{r}_t)^2}.$$

主要窗口为 $n = 30$ ，而 $n = 14$ 用作稳健性检验。数值不进行年化。一条在第 t 日形成的数据行预测

$$y_t = RV_{t+1}^{(n)},$$

滚动历史波动率则设定 $\hat{y}_t = RV_t^{(n)}$ 。

特征缩放仅在相应的训练部分上进行拟合：

$$z_{tj} = \frac{x_{tj} - \mu_{j, \text{train}}}{\sigma_{j, \text{train}}}.$$

随后，滞后线性模型求解带轻微正则化的目标函数，

$$\hat{\beta} = \operatorname{argmin}_{\beta} \sum_{t \in \text{train}} (y_t - z_t^{\top} \beta)^2 + \lambda \|\beta\|_2^2,$$

其中， $\lambda = 10^{-8}$ 用于提升数值稳定性，而不是进行强收缩。随机森林对 B 棵已拟合的树取平均，

$$\hat{y}_t^{\text{RF}} = \frac{1}{B} \sum_{b=1}^B T_b(z_t).$$

对于 LSTM，输入和前一隐藏状态决定诸如 $f_t = \sigma(W_f[x_t, h_{t-1}] + b_f)$ 的门；单元状态通过 $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$ 更新，最终隐藏表示被映射为一个波动率估计值。这些方程描述信息流，而不是对每个学习权重的直接经济解释。

GARCH(1,1) 将单步条件方差建模为

$$h_{t+1} = \omega + \alpha \varepsilon_t^2 + \beta h_t.$$

这里， α 衡量冲击响应， β 衡量持续性。最终估计值为 $\alpha = 0.10$ 、 $\beta = 0.78$ ，且 $\alpha + \beta = 0.88$ 。网格搜索选择 α 和 β ；方差目标法意味着 $\omega = (1 - \alpha - \beta) \hat{\sigma}_r^2$ ，因此报告的三个参数并不是三个相互独立搜索的量。

为了将条件方差映射到滚动目标，设 S_t 和 Q_t 分别为已知的前 $n-1$ 个收益率之和及平方和。在条件均值为零的情况下，

$$E\left[s_{t+1}^2 \mid F_t\right] = \frac{Q_t + h_{t+1} - (S_t^2 + h_{t+1}) / n}{n-1}.$$

因为目标是标准差，而且评估采用平方误差，所以主要实现以确定性的 80 点高斯-埃尔米特求积估计 $E[s \mid F_t]$ 。解析式 $\sqrt{E[s^2 \mid F_t]}$ 被保留为敏感性检验，因为当平方根为凹函数时，两个表达式并不相同。

对于 m 个测试观测值，

$$\text{MAE} = \frac{1}{m} \sum_{t=1}^m |y_t - \hat{y}_t|, \quad \text{RMSE} = \sqrt{\frac{1}{m} \sum_{t=1}^m (y_t - \hat{y}_t)^2}.$$

RMSE 对较大的预测偏差赋予更大权重；MAE 表示典型绝对偏差。QLIKE 在方差尺度上计算：

$$v_t = \max(y_t^2, \varepsilon), \quad \hat{v}_t = \max(\hat{y}_t^2, \varepsilon), \quad \text{QLIKE} = \frac{1}{m} \sum_{t=1}^m \left(\frac{v_t}{\hat{v}_t} - \ln \frac{v_t}{\hat{v}_t} - 1 \right),$$

其中 $\varepsilon = 10^{-12}$ 用于避免未定义值，数值越低越好。QLIKE 是针对不完美波动率代理值的相关补充指标（Patton, 2011），但本文高度重叠的滚动代理值并不等同于论文中的潜在条件方差设定。第 b 个自助法重复样本使用下式将每个模型与滚动模型比较：

$$\Delta_b = \text{RMSE}_b(M) - \text{RMSE}_b(\text{Rolling}),$$

因此，负值表示竞争模型更优。

4. 方法论

4.1 数据收集、质量与刷新控制

日度 OHLCV 蜡烛图由 Hyperliquid 的公开 `candleSnapshot` 端点提供 (Hyperliquid, 2026)。在返回的 1,241 行中，依据结束时间戳剔除了仍未收盘的一根蜡烛图。最终纳入的归档数据包含 1,240 根完整蜡烛图，时间跨度为 2023 年二月 26 日至 2026 年七月 19 日 (2026-07-19)。

质量门控检查数据结构、时间戳顺序和唯一性、日度间隔、交易品种、时间周期、价格为正、OHLC 排序以及交易活动指标非负。未发现任何严重问题；所有观察到的起始时间间隔均为 86,400,000 毫秒。原始蜡烛图、处理后的波动率和质量报告分别存储。永续期货并不等同于现货 BTC-USD，因此结论仍然具有特定市场局限性。

对于日度目标，蜡烛图完成判定规则尤为重要。一个尚未完全形成的收盘价会同时改变最新收益率、滚动波动率、成交量和交易笔数，使最后一行无法与此前每根完整蜡烛图相比较。

2025 年十一月 16 日这一截点由原始时间顺序划分得出，之后即予以固定。新蜡烛图会延长测试集结束日期，而不会移动其起始日期或成为训练行。为了使用同一代码进行比较，最终流程分别在截至七月 12 日的切片和截至七月 19 日的当前输入上运行。追加的七日数据在同一段市场历史中提供了一次类似前瞻式的稳定性检验。

4.2 特征构建与泄漏控制

收益率、活动变量、滞后项和滚动指标只使用在预测起点 t 时已观测到的信息；目标随后被移至 $t + 1$ 。导出的数据同时保留起点 `date` 和预测的 `target_date`。在按时间顺序划分之前，移除预热阶段的缺失行。

`realised_volatility_30d` 和 `rolling_return_std_30d` 在浮点精度范围内是相同的数学特征。同时保留二者会重复计算持续性、分散重要性，并增加某一特征在树中被选中的概率。因此，匹配的滚动标准差列被排除，最终保留 25 个表格输入和八个 LSTM 输入。

最终的 30 日数据框包含 1,195 行，日期从 2023 年四月 11 日到 2026 年七月 18 日。固定训练部分包含 950 个预测起点行，截止于 2025 年十一月 15 日；测试集包含 245 个起点，日期从 2025 年十一月 16 日到 2026 年七月 18 日，目标日期则持续到七月 19 日。没有使用随机训练—测试打乱。表格数据缩放仅在训练集上拟合。LSTM 缩放在其按时间顺序划分的内部验证区块之前拟合，因此验证集和测试集分布不会影响缩放参数。

即便截点相同，不同模型的有效训练样本数也不同。线性回归和随机森林使用 950 个带标签的数据行。LSTM 使用 921 个按时间顺序排列的序列，其中 783 个是拟合序列，138 个是内部验证序列。GARCH 使用 993 个截点前收益率估计其收益率过程，其中包括无法形成完整特征行的预热历史。滚动模型没有拟合样本。报告这些样本数，可以避免暗示结构不同的模型使用完全相同的观测值。

各模型最重要的共同限制是：预测时只能使用当时已经出现的数据。它们的输入并不相同。线性回归和随机森林使用 25 个整理后的特征，LSTM 使用八个序列特征，GARCH 使用收益率，滚动模型使用当前代理值。GARCH 先预测条件方差，再转换为滚动目标；监督学习模型直接预测目标。因此，本文比较的是各方法的完整实现，不能把结果差异全部归因于模型类型。

4.3 模型

滚动历史波动率。 该基准模型将今日的滚动代理指标向前延续一天。它没有拟合参数，并直接利用相邻窗口之间的重叠。

GARCH(1,1)。确定性的、由粗到细的高斯最大似然网格搜索与方差目标法相结合。似然函数对 r_t 的评分先使用 h_t ，再由 r_t^2 更新 h_{t+1} ，从而避免当前冲击进入其自身方差。参数在主要测试期间保持固定，但每当新的收益率变为可观测时，条件方差就会更新。预测按日期对齐，映射缺失或重复都会导致流程失败。

滞后线性回归。使用岭参数 10^{-8} 在标准化输入上拟合线性方程。每个系数均被导出。系数描述标准化尺度上的关联；相互相关的滞后指标仍然使因果解释不成立。

随机森林。实验模型改为标准的 `sklearn.ensemble.RandomForestRegressor`，不再使用项目内近似实现。六个预先规定的候选组合采用 300 棵树、平方根特征抽样，并组合最大深度（5、8、不限制）和最小叶节点大小（5、10）。训练期最后 15% 构成时间顺序验证区块，以验证 RMSE 选择候选，QLIKE 只用于打破并列。选中的“不限制深度、最小叶节点 5”配置使用种子 42 在全部 950 个测试前数据行上重新拟合。不纯度重要性、十次事后留出集置换重要性和袋外诊断均被导出。

LSTM。长度为三十个观测值的序列输入一个 LSTM 层、16 单元 ReLU 层和一个输出。四个预先规定的隐藏单元数/学习率组合（16 或 32；0.001 或 0.003）在训练序列最后 15% 的时间顺序验证区块上比较。验证 MSE 用于选择候选和提前停止，最终测试集完全不参与选择。选中模型包含 32 个隐藏单元、学习率 0.003、批量大小 32、权重衰减 $1e-5$ 、5,921 个参数，并选择第 20 个轮次。种子 7、42 和 101 检验优化敏感性。事后特征消融把某一标准化输入在所有序列步替换为训练均值，它只用于解释，不参与调参。

4.4 评估与决策规则

主要结果来自固定截点的时间顺序留出集。模型参数和权重不会每日重新拟合。随机森林和 LSTM 的候选数量不完全相同，但均使用相同的“只在训练期进行时间顺序验证”的规则，最终留出集不参与选择。GARCH 使用确定性似然网格，滚动模型无需选择，线性回归只采用固定的数值稳定岭项。补充的扩展窗口设计把测试期划分为四个有序区块，并在之后边界重新拟合各流程。

稳健性检验还包括 14 日和 30 日目标、按时间顺序划分的测试期前后两半，以及根据已实现测试目标定义的低、中、高波动率三分位状态。这些状态是事后诊断分组，而不是实时分类。配对循环移动区块自助法以 30 日为区块长度重采样 2,000 次。三十日与主要目标的重叠长度一致，有助于保留局部依赖关系（Künsch，1989）。百分位区间描述这一重采样设计下的不确定性；它们并不是普适的显著性保证。

四个比较方面分别报告如下：

维度	使用的证据	决策规则
准确性	RMSE、MAE 和方差尺度 QLIKE	RMSE 决定显示排名；必须讨论 MAE 或 QLIKE 不一致之处
稳健性	目标窗口、前后两半、分段、状态、刷新和自助法	所声称的优势不应依赖于一个边界或少量日期
可解释性	公式、参数、系数、重要性或记录的架构	只认可流程实际产生的解释
实用性	拟合/预测时间、依赖项和结构规模	计时是本地实现证据，而非普适速度结论
可复现性	固定日期、种子、配置、元数据和测试	另一次运行应能复现该设计，并解释任何由数据驱动的变化

只有当复杂模型带来明显而且稳定的改进时，额外的解释和实现难度才值得。

5. 结果

5.1 主要 30 日目标

排名	模型	MAE	RMSE	QLIKE	相对滚动基准 RMSE
1	GARCH(1,1)	0.00047642	0.00098502	0.00370047	-30.994%
2	滞后线性回归	0.00073861	0.00140087	0.00623445	-1.861%
3	滚动历史波动率	0.00062843	0.00142744	0.00669043	0.000%
4	LSTM	0.00104907	0.00174351	0.00816805	+22.142%
5	随机森林	0.00128867	0.00220594	0.01170773	+54.538%

GARCH 的 MAE、RMSE 和 QLIKE 均最低。QLIKE 与 RMSE 给出完全相同的排序，因此结果并非只由标准差尺度的平方误差选择造成。其相对于滚动基准的 RMSE 差值为 -0.00044242 ，相当于降低 30.994%。

线性回归按 RMSE 和 QLIKE 排名第二，但 MAE 高于滚动基准，因此其小幅优势仍需不确定性证据。LSTM 和随机森林的 RMSE 分别比滚动基准高 $+0.00031607$ 和 $+0.00077850$ 。

去重后，两种森林重要性方法都依次将当前 30 日波动率、其一日滞后值、30 日平均绝对收益率以及当前波动率的两日滞后值排在最高位置。这些是关联而非因果；森林在很大程度上是在重构由更简单模型以更简洁方式表达的持续性。




图 1. 所展示测试区间内的实际下一日滚动波动率代理值与预测值。底层 CSV 保留每个测试观测值；为确保可读性，图表限制了可见时段。

在持续性较强的时段，所有预测都能紧密跟踪目标，而波动率水平的变化会造成最大差异。因此，必须结合波动率状态和自助法证据来解读该图，而不能让平静时期或某一次显眼的预测失误决定排名。

这也说明了为什么仅靠目视检查并不充分：数条彩色路径在很长的区间内相互重合，但在数量相对较少的剧烈转折处，其误差对 RMSE 的贡献不成比例。MAE、不同波动率状态下的偏差以及重采样差值揭示了压缩图可能掩盖的方面。

5.2 目标、时间及不确定性方面的稳健性

目标窗口	GARCH RMSE	线性回归 RMSE	滚动基准 RMSE	LSTM RMSE	随机森林 RMSE
14 日	0.00178208	0.00260295	0.00276213	0.00364246	0.00397432
30 日	0.00098502	0.00140087	0.00142744	0.00174351	0.00220594

GARCH 在 14 日目标中排名第一，比滚动基准低 35.482%。这一较短窗口下，每个模型的误差都更大，因为每个新进入或离开窗口的收益率都有更大影响。GARCH 在两个测试半段中也都排名第一，RMSE 分别为 0.00128466 和 0.00054380。

模型	相对于滚动基准的 RMSE 差值点估计	30 日区块自助法区间	偏向该模型的重采样占比
GARCH(1,1)	-0.00044242	[-0.00099670, -0.00017158]	100.00%
滞后线性回归	-0.00002657	[-0.00009605, 0.00003681]	80.45%
LSTM	+0.00031607	[0.00000898, 0.00063980]	2.00%
随机森林	+0.00077850	[0.00008093, 0.00137210]	0.05%

GARCH 的区间始终低于零；线性回归的区间跨过零。两个机器学习模型的区间均高于零：只有 2.00% 的重采样偏向 LSTM，0.05% 偏向随机森林。这支持总体表现不佳的结论，而非由少数孤立误差造成。

5.3 滚动预测起点、波动率状态与诊断

对于 GARCH、线性回归、滚动基准、LSTM 和随机森林，拼接各折后的 RMSE 分别为 0.00098681、0.00139934、0.00142744、0.00203235 和 0.00218005；对应 QLIKE 为 0.00371082、0.00616854、0.00669043、0.00991574 和 0.01150384，排序相同。

LSTM 在局部具有竞争力：它在第 1 折和第 4 折中排名第三，两折的 RMSE 均为 0.00082578，略低于滚动基准和随机森林，但并未低于线性回归。它在第 2 折和第 3 折中降至第四，因此这些局部优势不足以证明总体稳定性。

GARCH 在低、中、高波动率状态下的 RMSE 分别为 0.00065099、0.00058047 和 0.00146368。其高波动率状态偏差为 -0.00015218，表明在风险最重要时，其预测平均略有低估。

随机森林在全部 950 个训练行上的 OOB RMSE 为 0.00128268，而时间顺序测试 RMSE 为 0.00220594，差距为 0.00092326。OOB 树可以使用训练期中较晚的行，因此该指标诊断内部预测，而非未来时间验证。

随机种子 7、42 和 101 对应的 LSTM RMSE 分别为 0.00184673、0.00174351 和 0.00178917，选定轮次分别为 11、20 和 33。0.00010322 的极差显示优化差异，但每次运行仍高于滚动基准。

5.4 七日刷新稳定性

后一次刷新追加了完整蜡烛图，同时保留 2025 年十一月 16 日这一边界，从而在不重新分配先前测试观测值的情况下检验稳定性。

模型	使用截至七月 12 日数据的 RMSE	使用截至七月 19 日数据的 RMSE	排名变化
GARCH(1,1)	0.00099309	0.00098502	1 → 1
滞后线性回归	0.00141843	0.00140087	2 → 2
滚动历史波动率	0.00144481	0.00142744	3 → 3
LSTM	0.00176625	0.00174351	4 → 4
随机森林	0.00223669	0.00220594	5 → 5

新增一周使每个模型的 RMSE 均下降约 0.8–1.4%，但所有排名均保持不变。这是一项程序性稳定性检查，而不是独立重复研究。

5.5 GARCH 转换敏感性

条件方差转换方式	MAE	RMSE	QLIKE
$E[s F_t]$ ，80 点高斯-埃尔米特求积	0.00047642	0.00098502	0.00370047
$\sqrt{E[s^2 F_t]}$ ，解析法敏感性检验	0.00048149	0.00098447	0.00369775

解析法敏感性检验的平均预测值高出 0.00000950，RMSE 低 0.00000055，QLIKE 低 0.00000272。差异很小，两种转换下 GARCH 都排名第一，因此这一选择不影响主要结论。数值求积仍作为主要方法，因为它估计标准差目标的条件均值。

5.6 实用性与可解释性

模型	本地拟合/预测时间	选择与依赖	结构及解释证据
滚动基准	0.000000 / 0.000010 s	无；NumPy/Pandas	0 个参数；直接持续性规则
线性回归	0.000227 / 0.000014 s	固定数值岭项；NumPy	26 个系数；全部带符号导出
GARCH(1,1)	0.530158 / 0.011173 s	确定性似然网格；NumPy	3 个报告参数；冲击响应与持续性
随机森林	1.384994 / 0.007129 s	6 个验证候选；scikit-learn	57,970 个节点；重要性与 OOB
LSTM	11.051759 / 0.003069 s	4 个候选加提前停止；PyTorch	5,921 个权重；损失、种子与消融

运行时间本身不能证明部署实用性。滚动和线性几乎无需调参；GARCH 增加确定性网格与目标转换；随机森林增加库依赖和六个候选；LSTM 还需要 PyTorch、梯度优化、提前停止和种子稳定性检查。这些只是本地实现证据，不能推出 GARCH 在所有部署中都更快。

线性回归中绝对值最大的六个非截距标准化系数如下：

特征	系数
当前 30 日代理值	+0.00603107
14 日收益率标准差	+0.00058092
30 日平均绝对收益率	+0.00039447

特征	系数
7 日平均绝对收益率	+0.00037525
代理值一日滞后	-0.00032560
7 日收益率标准差	-0.00030675

滚动特征彼此相关，因此系数符号是有条件的关联，而非因果。随机森林的不纯度和置换排名均把当前代理值列为第一。LSTM 中，把当前标准化代理值替换为训练均值会使 RMSE 增加 0.00465173；消融 30 日平均绝对收益率会增加 0.00080347。这些检查只识别出机械影响已拟合预测的输入，不能解释循环状态或证明因果关系。

6. 讨论

GARCH 在 MAE、RMSE 和 QLIKE 上都排名第一，并在两个目标窗口、两个测试半段、每个扩展窗口和每个波动率区间中保持第一。滚动模型是最简单的基准。线性回归的 RMSE 只改善 1.861%，但 MAE 更差，而且自助法区间跨过零。随机森林和 LSTM 的总体误差更高，也需要更多设置和依赖。

这里没有把解释难度或运行时间硬换成一个总分。先看误差是否真的改善，再看这种改善在其他测试中是否保持，最后比较为此增加了多少解释和实现难度。

GARCH 的表现具有理论合理性。条件方差对最近的平方冲击作出响应，同时通过 β 保留早期方差。其持续性为 0.88，表明其具有显著记忆性，同时仍低于平稳性边界。滚动目标转换也为 GARCH 提供了一项相关任务：下一个 30 日窗口中的 29 个收益率是已知的，而对新进入窗口的收益率之不确定性则由 h_{t+1} 提供。滚动基准假设新进入的观测不会产生可预测的更新；GARCH 用估计的方差贡献取代了这一假设。

高斯-埃尔米特检验说明，期望标准差并不完全等于期望方差的平方根。两者的平均预测值只相差 0.00000950，RMSE 只相差 0.00000055，而且 GARCH 在两种转换下都排名第一。因此，转换方法的这点差异不会改变主要结论。

滚动基准的强势表现部分源于目标本身的构造。明日窗口与今日窗口高度重叠，因此持续性既是目标构造的数学结果，也是一种市场模式。这使滚动基准对于单日操作更新而言是公平的，但对于完全属于未来且不重叠的预测期限，它可能低估更丰富模型的价值。这也解释了为什么很小的 RMSE 优势不应自动被称为具有实际重要性。

线性回归说明了排名与有意义改善之间的区别。其 RMSE 比滚动基准低 1.861%，但其 MAE 更高，而且自助法区间跨过零。因此，称其明确更优会夸大证据。移除完全重复的滚动标准差特征后，系数证据的误导性有所降低，但其余的滞后变量和窗口变量仍相互关联。系数符号反映的是可审计的关联，而非独立的因果效应。

随机森林没有在总体上超过简单模型。它最重要的特征主要是近期波动率，说明森林的大量结构仍在学习持续性。袋外误差与较晚测试期误差之间的差距，也说明训练期内有效的关系不一定能跨时期保持。特征重要性只能说明关联，不能解释一次具体预测的原因。

LSTM 在第 1 折和第 4 折中排名第三，略优于滚动基准和随机森林，但未优于线性回归。其总体 RMSE 与 QLIKE、高波动率表现、其他折和种子范围都表明局部优势并不可靠。消融显示它高度依赖当前代理值，却仍无法透明解释单次预测。因此，本结论只适用于当前日度数据和直接目标 LSTM 流程：该流程没有提供稳健收益，不能据此判断 LSTM 普遍无效。

综合误差、稳定性和解释难度，GARCH 是本实验中最合适的选择。它的 RMSE 比滚动基准低 30.994%，而且可以用近期冲击和持续条件方差来解释。高波动率区间的偏差 -0.00015218 仍需注意：总体表现最好，不代表压力期预测一定足够保守。滚动模型仍是最容易实施的备选。

固定截点刷新可防止结果漂移：重新计算 80/20 切分会同时改变数据和实验。冻结起始点可使新增的七日数据延长既定留出集。所有排名保持不变，每个模型的 RMSE 均略有下降，因此核心结论经受住了这项短期检查。

代码检查发现了几处会影响结果的问题。日期映射修正了索引错位；在更新方差前先对收益率评分，避免了前视；滚动目标转换也得到修正。后续检查还排除了未收盘日线、分开保存预测日期和目标日期、删除重复特征、固定测试截点、改用 scikit-learn 随机森林，并加入 QLIKE。现在共有 43 项自动测试覆盖主要日期、公式、输出和文档渲染。

仍存在六项局限。第一，只使用一种资产和一家交易所。第二，目标是高度重叠的日度代理值，而非高频已实现方差。第三，全部稳健性检验仍属于同一段市场历史。第四，GARCH 在厚尾收益率上仍使用高斯似然。第五，随机森林和 LSTM 的紧凑搜索只使用一个时间顺序验证区块，而不是完全嵌套的时间序列优化。最后，各流程的特征、有效样本与目标转换并不相同。本设计控制信息时间，但不能分离纯粹的“架构效应”，也不能证明盈利能力。

更有力的扩展方案应预留另一个未曾使用的未来时期，使用日内收益率构建已实现方差，检验 Student-t 或非对称 GARCH，并在嵌套的按时间顺序验证中调优机器学习模型。混合模型可以将 GARCH 方差作为非线性模型的输入。情绪是另一个可能增加的因素：Brauneis 和 Sahiner (2026) 发现了非线性情绪效应，尽管结果因币种而异，而比特币是一个重要例外。各项扩展应分别引入，以便任何改善的来源仍可识别。

7. 结论

本项目研究：在预测 Hyperliquid 比特币永续期货波动率代理值的次日更新时，与滚动历史波动率和 GARCH(1,1) 相比，随机森林和 LSTM 增加的复杂度在多大程度上值得。本次结果没有显示这两种机器学习流程带来足以支持额外复杂度的改进。GARCH 的 RMSE 为 0.00098502、QLIKE 为 0.00370047，RMSE 比滚动基准低 30.994%，并在两个目标窗口、两个测试半段、四个扩展窗口和三个波动率区间中排名第一。

线性回归接近滚动基准，但 MAE 更差，而且 RMSE 差值区间跨过零。LSTM 只在少数分段中有竞争力，随机森林仍不及滚动基准。结论只限于测试的数据、目标、输入和流程。不同数据或设计可能得到另一种排名；这里的结果不排除非线性方法在其他场景有价值。

参考文献

Bollerslev, T. (1986) ‘广义自回归条件异方差’，*计量经济学杂志*，31(3)，第 307–327 页。获取地址：[https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)。

Brauneis, A. 和 Sahiner, M. (2026) ‘加密货币波动率预测：HAR、情绪与机器学习竞赛’，*亚太金融市场*，33，第 379–411 页。获取地址：<https://doi.org/10.1007/s10690-024-09510-6>。

Breiman, L. (2001) ‘随机森林’，*机器学习*，45，第 5–32 页。获取地址：<https://doi.org/10.1023/A:1010933404324>。

Catania, L.、Grassi, S. 和 Ravazzolo, F. (2019) ‘模型与参数不稳定条件下的加密货币预测’，*国际预测杂志*，35(2)，第 485–501 页。获取地址：<https://doi.org/10.1016/j.ijforecast.2018.09.005>。

- Dudek, G., Fiszeder, P., Kobus, P. 和 Orzeszko, W. (2024) ‘使用统计和机器学习方法预测加密货币波动率：一项比较研究’，*应用软计算*，151，111132。获取地址：<https://doi.org/10.1016/j.asoc.2023.111132>。
- Hansen, P.R. 和 Lunde, A. (2005) ‘波动率模型预测比较：是否有任何模型能击败 GARCH(1,1)？’，*应用计量经济学杂志*，20(7)，第 873–889 页。获取地址：<https://doi.org/10.1002/jae.800>。
- Hochreiter, S. 和 Schmidhuber, J. (1997) ‘长短期记忆’，*神经计算*，9(8)，第 1735–1780 页。获取地址：<https://doi.org/10.1162/neco.1997.9.8.1735>。
- Huang, Z.-C., Sangiorgi, I. 和 Urquhart, A. (2024) ‘使用机器学习技术预测比特币波动率’，*国际金融市场、机构与货币杂志*，97，102064。获取地址：<https://doi.org/10.1016/j.intfin.2024.102064>。
- Hyperliquid (2026) ‘Info 端点’，*Hyperliquid* 文档。获取地址：<https://hyperliquid.gitbook.io/hyperliquid-docs/for-developers/api/info-endpoint>（访问日期：2026 年七月 20 日）。
- Katsiampa, P. (2017) ‘比特币波动率估计：GARCH 模型的比较’，*经济学快报*，158，第 3–6 页。获取地址：<https://doi.org/10.1016/j.econlet.2017.06.023>。
- Künsch, H.R. (1989) ‘一般平稳观测的刀切法与自助法’，*统计学年刊*，17(3)，第 1217–1241 页。获取地址：<https://doi.org/10.1214/aos/1176347265>。
- Lundberg, S.M. 和 Lee, S.-I. (2017) ‘解释模型预测的统一方法’，*神经信息处理系统进展*，30。获取地址：<https://arxiv.org/abs/1705.07874>。
- Molnar, C. (2025) *可解释机器学习：使黑箱模型可解释的指南*。第 3 版。获取地址：<https://christophm.github.io/interpretable-ml-book/>（访问日期：2026 年七月 20 日）。
- Patton, A.J. (2011) ‘使用不完善波动率代理值进行波动率预测比较’，*计量经济学杂志*，160(1)，第 246–256 页。获取地址：<https://doi.org/10.1016/j.jeconom.2010.03.034>。
- Shen, Z., Wan, Q. 和 Leatham, D.J. (2021) ‘比特币收益率波动预测：GARCH 与 RNN 的比较研究’，*风险与金融管理杂志*，14(7)，337。获取地址：<https://doi.org/10.3390/jrfm14070337>。
- Zahid, M., Iqbal, F. 和 Koutmos, D. (2022) ‘使用结合机器学习的混合 GARCH 模型预测比特币波动率’，*风险*，10(12)，237。获取地址：<https://doi.org/10.3390/risks10120237>。